In [55]:
```python
import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings('ignore')
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
```

In [3]:
```python
sales_df = pd.read_csv('C:/Users/Isaac/Desktop/IHD/EBAC DT/CIENCIA DE DATOS/M53 DS/Advertising.csv')
sales_df
```

Out[3]:

	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	12.0
3	151.5	41.3	58.5	16.5
4	180.8	10.8	58.4	17.9

In [31]:
```python
X = sales_df[['TV','Radio','Newspaper']].values
Y = sales_df[['Sales']].values
```

In [17]:
```python
# graficamos para ver la distribución de los datso

cols = ['TV','Radio','Newspaper']
for col in cols:
    plt.figure(figsize = (5,4))
    plt.plot(sales_df[col], sales_df['Sales'], 'ro')
    plt.title(f'Ventas con respecto a canal de publicidad {col}')
    plt.show()
```

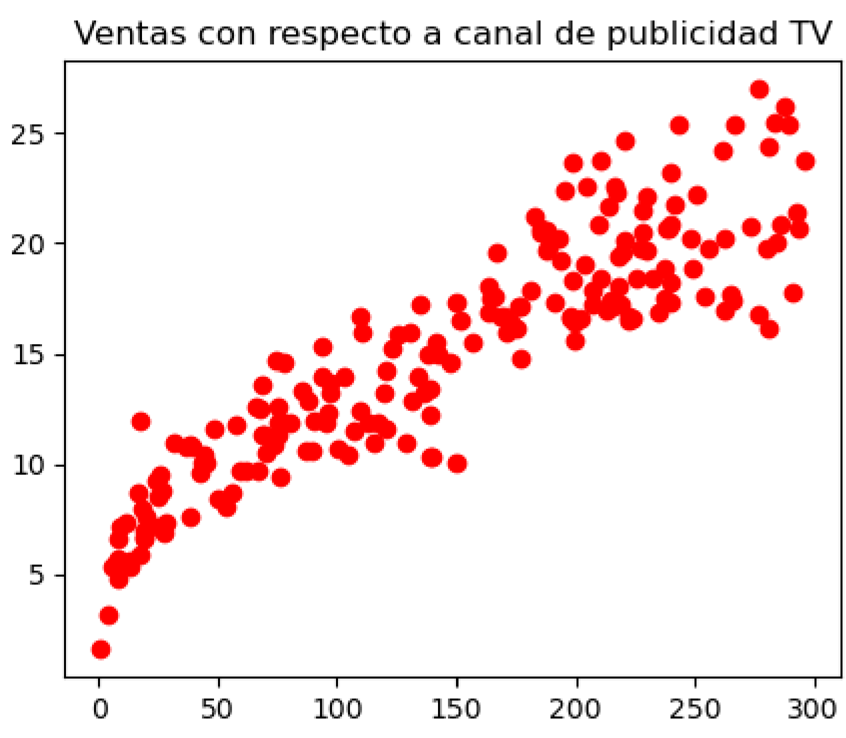

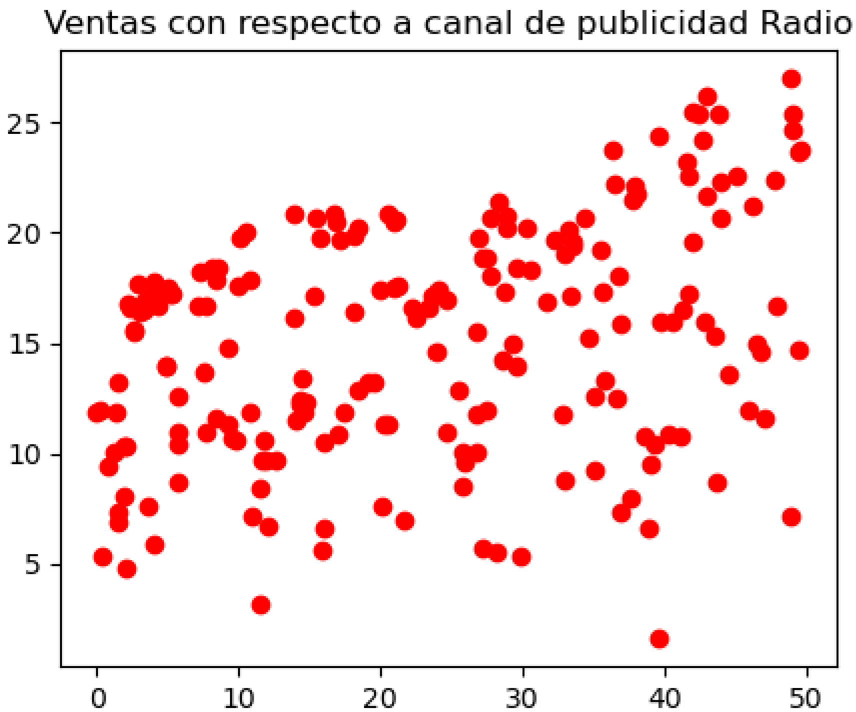

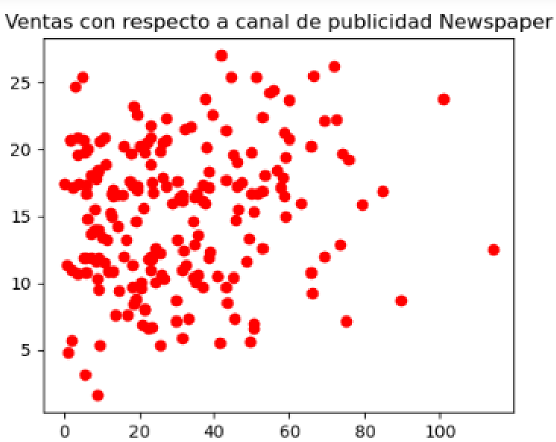

* **Observaciones:**

- Podemos observar en la grafica de TV, entre mas publicidad hay, más ventas hay, existe una correlación entre publicidad y venta
- La publicidad en Radio, si hay un aumento de la publicidad pero ya no hay una correlación tan clara que indique que entre más publicidad haya más ventas.
- En peridioco no hay correlacion alguna.

In [20]:

```python
# Modelo de resgresion Lineal multiple

from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
```

In [34]:

```python
# dividimos nuestroc onjunto de datos en entrenamiento y test

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.3, random_state = 1)

# inicializamos y entrenamos el modelo
model_reg = LinearRegression()
model_reg.fit(X_train, Y_train)

# hacemos predicciones
y_pred = model_reg.predict(X_test)

# obtenemos metricas, evaluamos el modelo
rmse = mean_squared_error(Y_test, y_pred)
print('RMSE : ', rmse)
print('R2 :', r2_score(Y_test, y_pred))

#graficamos

sns.regplot(x = Y_test, y = y_pred)
```

```
RMSE :  2.370659971225658
R2 : 0.9071151423684273
```

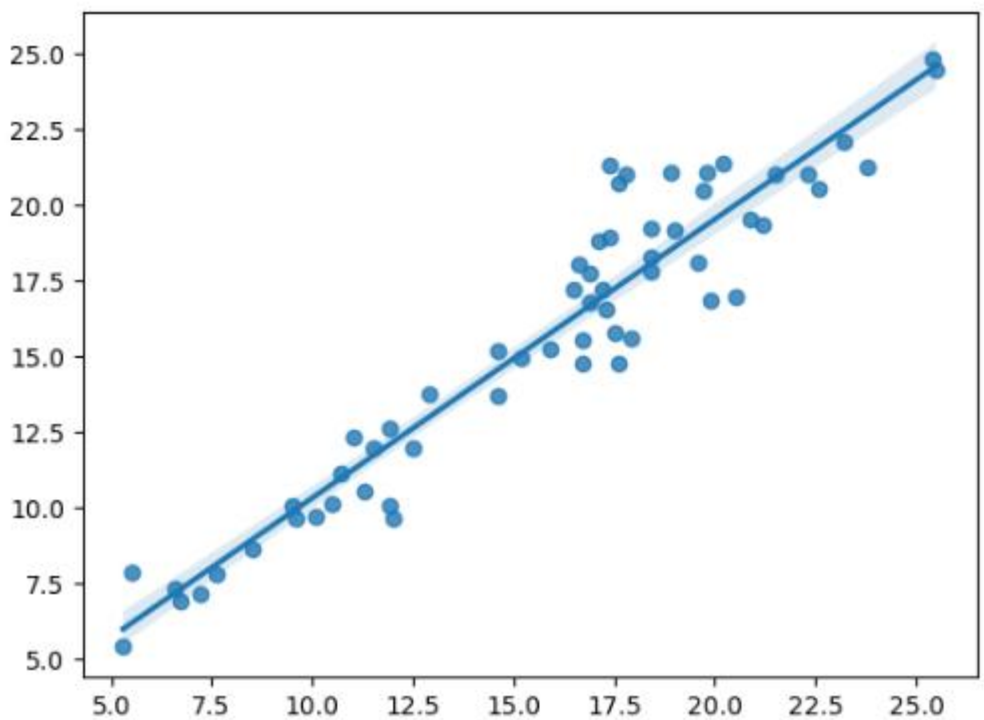

In [35]:
```
# dividimos nuestroc onjunto de datos en entrenamiento y test

X1 = sales_df[['TV','Radio']] # utilizamos solo 2 variables
X_train, X_test, Y_train, Y_test = train_test_split(X1, Y, test_size = 0.3, random_state = 1)

# inicializamos y entrenamos el modelo
model_reg = LinearRegression()
model_reg.fit(X_train, Y_train)

# hacemos predicciones
y_pred = model_reg.predict(X_test)

# obtenemos metricas, evaluamos el modelo
rmse = mean_squared_error(Y_test, y_pred)
print('RMSE : ', rmse)
print('R2 :', r2_score(Y_test, y_pred))

#graficamos

sns.regplot(x = Y_test, y = y_pred)
```

```
RMSE :  2.3645069433762362
R2 : 0.9073562242286407
```

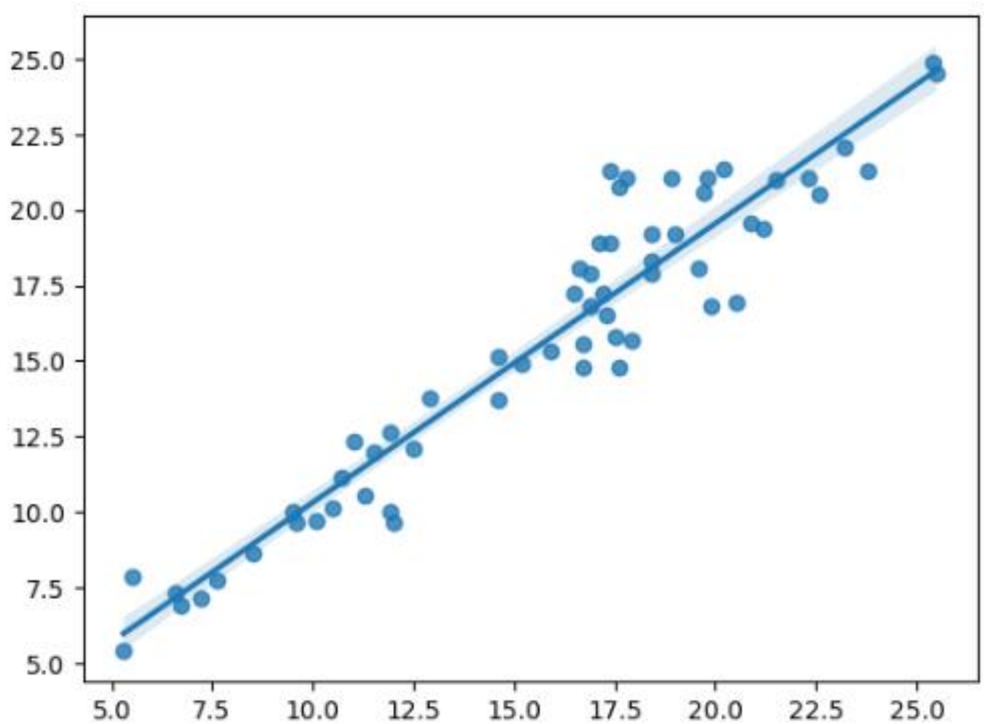

** Hay una mejora en los valores de las metricas cuando solo utilizamos 2 variables en el modelo 'TV','Radio', que son las que tienen mayor relavancia para el modelo.

¿Qué tan bueno es el ajuste?

RMSE (Root Mean Squared Error):

- Un RMSE más bajo es mejor ** Un RMSE de aproximadamente 2.36 indica que, en promedio, las predicciones del modelo se desvían en alrededor de 2.37 unidades de las ventas reales.

R² (Coeficiente de Determinación):

- Un R² de aproximadamente 0.90 significa que el modelo explica el 90% de la variabilidad en las ventas en función de las variables de entrada (TV, Radio, Newspaper). ** Esto es algo positivo pero podria mejorar, lo que indica que el modelo se ajusta a los datos.

In [48]:

```
# obtenemos el intervalo de confinza del 90%
import statsmodels.api as sm
from statsmodels.tools import add_constant

X_train_sm = sm.add_constant(X_train)
model_sm = sm.OLS(Y_train, X_train_sm).fit()

# Resumen del modelo
print(model_sm.summary())
```

```
                            OLS Regression Results                            
==============================================================================
Dep. Variable:                      y   R-squared:                       0.899
Model:                            OLS   Adj. R-squared:                  0.898
Method:                 Least Squares   F-statistic:                     612.0
Date:                Thu, 24 Oct 2024   Prob (F-statistic):           4.95e-69
Time:                        15:39:55   Log-Likelihood:                -272.37
No. Observations:                 140   AIC:                             550.7
Df Residuals:                     137   BIC:                             559.6
Df Model:                           2                                         
Covariance Type:            nonrobust                                         
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          4.6390      0.350     13.240      0.000       3.946       5.332
TV             0.0550      0.002     32.903      0.000       0.052       0.058
Radio          0.1016      0.010     10.677      0.000       0.083       0.120
==============================================================================
Omnibus:                       14.841   Durbin-Watson:                   2.038
Prob(Omnibus):                  0.001   Jarque-Bera (JB):               24.663
Skew:                          -0.512   Prob(JB):                     4.41e-06
Kurtosis:                       4.783   Cond. No.                         407.
==============================================================================
```

In [50]:
```
# Intervalo de confianza del 90% para las predicciones

X_val = np.array([[110,50,70]])
X_val_sm = sm.add_constant(X_val)

pred_val = model_sm.get_prediction(X_val_sm)
inter_90 = pred_val.conf_int(alpha = 0.10) # intervalo de de confianza del 90%
print(f'Intervalo de confianza del 90% para la prediccion: {inter_90}')
```

```
Intervalo de confianza del 90% para la prediccion: [[457.08129111 583.23127778]]
```

In [82]:
```
# Residuos del modelo
resid = model_sm.resid
```

In [79]:
```
# Cálculo de la Asimitreía de Residuales.
import scipy
skew = float(scipy.stats.skew(resid, bias = True))
skew
```

Out[79]:
```
-0.512418218679359
```

In [59]:
```
# Calculo de Curtosis de Residuales.

Kurtosis = float(scipy.stats.kurtosis(resid, fisher = False))
Kurtosis
```

Out[59]:
```
4.782590640126672
```

* Supuesto 1: Supuesto de Normalidad de Residuales

Cálculo del estadistico de Jarque-Bera

In [60]:
```
JB = (len(Y) / 6 ) * (skew ** 2 + (Kurtosis -3) ** 2 / 4)
JB
```

Out[60]:
```
35.23265928004439
```

In [66]:
```
# Nivel critico de confianza al 90%

Nivel_confianza = 0.90
n_cri_conf = scipy.stats.chi2.ppf(Nivel_confianza, df = 2)
n_cri_conf
```

Out[66]:
```
4.605170185988092
```

Conclusión

In [68]:
```
print('JB:',JB, ">", 'Nivel Critico:', n_cri_conf, "Dado que JB es mayor al Nivel Critico,\n Podemo
```

```
JB: 35.23265928004439 > Nivel Critico: 4.605170185988092 Dado que JB es mayor al Nivel Critico,
 Podemos rechazar la hipotesis de existencia de Normalidad en los residuales
```

* **Supuesto 2: Inexistencia de correlación entre Residuales.**

In [71]:
```
def cal_durbin_watson(residuals):
    diff_resid = np.diff(residuals, axis = 0)
    dw_state = np.sum(diff_resid ** 2)/ np.sum(residuals ** 2)
    return dw_state

durbin_watson = cal_durbin_watson(resid)
print(f"Durbin-Watson: {durbin_watson}")
```

```
Durbin-Watson: 2.0375161916374998
```

Conclusión

*** Durbin-Watson: 2.037. Este valor es muy cercano a 2, lo que indica que no hay evidencia de autocorrelación en los residuos del modelo. Esto es positivo, ya que sugiere que los residuos son independientes entre sí, lo que es un supuesto importante para un buen ajuste de un modelo de regresión lineal.**

* **Supuesto 3: Homocedasticidad (igual de varianzas)**

In [85]:
```
from statsmodels.stats.diagnostic import het_white
exog = model_sm.model.exog
white_test = het_white(resid, exog)
print('Estadistico de Prueba:', white_test[0])
print('Valor P:', white_test[1])
```

```
Estadistico de Prueba: 11.353378151633752
Valor P: 0.044806641638718836
```

Conclusión

*** Dado que el valor p es menor que 0.05, rechazamos la hipótesis nula de homocedasticidad. Esto sugiere que hay heterocedasticidad en los residuos del modelo.**

Supuesto 4: Inexistencia de Multicolinialidad

In [86]:
```
from statsmodels.stats.outliers_influence import variance_inflation_factor
```

In [87]:
```
X_train_sm = pd.DataFrame(X_train_sm)
```

In [90]:
```
vif = pd.DataFrame()
vif['Variable'] = X_train_sm.columns
vif['VIF'] = [variance_inflation_factor(X_train_sm.values, i) for i in range(X_train_sm.shape[1])]
print(vif)
```

```
  Variable       VIF
0    const  5.867148
1       TV  1.001352
2    Radio  1.001352
```

Conclusión.

*** TV y Radio: Ambas tienen un VIF de 1. Esto indica que no hay multicolinealidad entre las variables. Es decir, las variables independientes TV y Radio no están correlacionadas entre sí de manera significativa, lo cual es bueno para el modelo.**